A. 平台搭建

一、 注册&登录 ModelScope

进入 ModelScope（https://www.modelscope.cn/home），右上角点击完成新用户的注册；

二、 获取计算资源

注册完成后，登录 ModelScope，进入首页，请确定已经绑定阿里云账 号，并已获得免费的配套云计算资源。启动 CPU 服务器：

三、 启动 Notebook 准备

环境配置

一、 点击 Terminal 图标，打开终端命令行环境

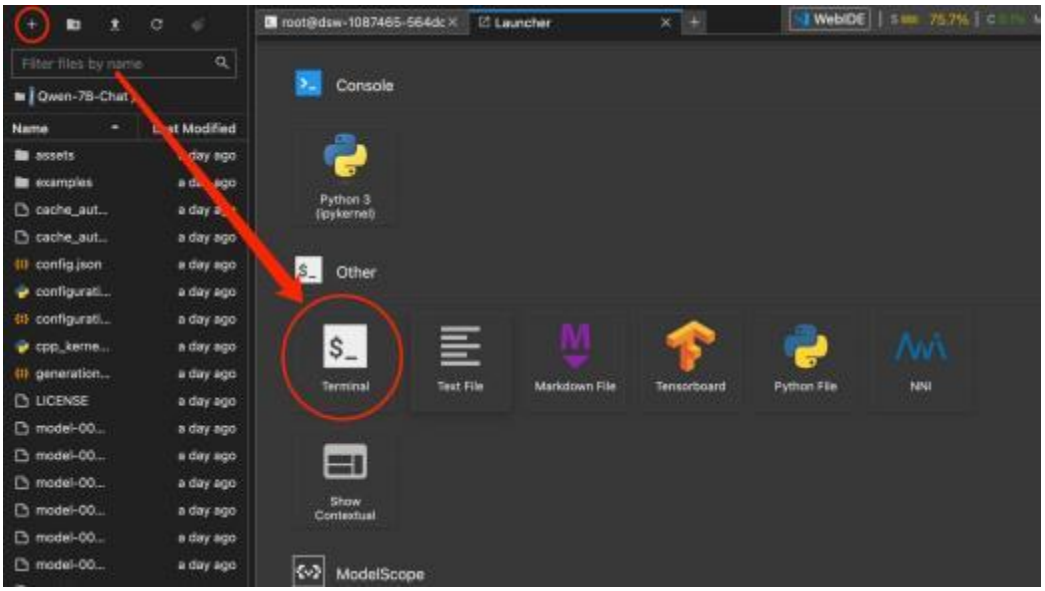

二、 环境搭建

以下根据是否选择在 conda 环境中运行实例自行选择操作步骤

- conda 环境： 步骤 1、2
- root 直接操作：2.2

1. CPU 版本发现并没有 conda,手动下载：

```
cd /opt/conda/envs
#问题：没有那个文件或目录
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh
bash Miniconda3-latest-Linux-x86_64.sh -b -p /opt/conda
echo 'export PATH="/opt/conda/bin:$PATH"' >> ~/.bashrc
source ~/.bashrc
conda --version
```

激活环境：

```
conda create -n qwen_env python=3.10 -y
source /opt/conda/etc/profile.d/conda.sh
conda activate qwen_env
```

2. 基础依赖

(1) 基础环境：

```
pip install \
  torch==2.3.0+cpu \
  torchvision==0.18.0+cpu \
  --index-url https://download.pytorch.org/whl/cpu
```

(2) 基础依赖

在执行前加一条命令检查 pip 是否能正常联网

```
pip install -U pip setuptools wheel
```

```
# 安装基础依赖（兼容 transformers 4.33.3 和 neuralchat）
pip install \
  "intel-extension-for-transformers==1.4.2" \
  "neural-compressor==2.5" \
  "transformers==4.33.3" \
  "modelscope==1.9.5" \
  "pydantic==1.10.13" \
```

```
  "sentencepiece" \
  "tiktoken" \
  "einops" \
  "transformers_stream_generator" \
  "uvicorn" \
  "fastapi" \
  "yacs" \
  "setuptools_scm"

# 安装 fschat（需要启用 PEP517 构建）
pip install fschat --use-pep517
```

3. 可选：安装 tqdm、huggingface-hub 等增强体验

```
pip install tqdm huggingface-hub
```

B. 大模型实践

一、 下载大模型到本地

1. 切换到数据目录

```
cd /mnt/data
```

2. 下载对应大模型

供参考的大模型，可自行调研配置

一次最好只跑下载一个大模型，否则会存储不足。

```
git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
```

```
Qwen-7B-Chat/
├── config.json
├── generation_config.json
├── pytorch_model-00001-of-00002.bin
├── pytorch_model-00002-of-00002.bin
├── tokenizer_config.json
├── tokenizer.model or tokenizer.json
├── model_index.json  (如是 ModelScope 格式)
├── README.md
```

二、 构建实例

1. 切换工作目录

```
cd /mnt/workspace
```

2. 实例代码：

编写推理脚本 run_qwen_cpu.py

```
from transformers import TextStreamer, AutoTokenizer, AutoModelForCausalLM

model_name = "/mnt/data/Qwen-7B-Chat"  # 本地路径
prompt = "请说出以下两句话区别在哪里？ 1、冬天：能穿多少穿多少 2、夏天：能穿多少穿多少"

tokenizer = AutoTokenizer.from_pretrained(
    model_name,
    trust_remote_code=True
)

model = AutoModelForCausalLM.from_pretrained(
    model_name,
    trust_remote_code=True,
    torch_dtype="auto"  # 自动选择 float32/float16（根据模型配置）
).eval()

inputs = tokenizer(prompt, return_tensors="pt").input_ids

streamer = TextStreamer(tokenizer)
outputs = model.generate(inputs, streamer=streamer, max_new_tokens=300)
```

三、 运行实例

```
python run_qwen_cpu.py
```

其他大预言模型部署

在完成上述实验后，可以进一步尝试下载及加载其他大语言模型进行部署实验的体验。推荐体验的开源模型列表

清华智谱（ZhipuAI）

```
git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
git clone https://www.modelscope.cn/ZhipuAI/chatglm2-6b.git
git clone https://www.modelscope.cn/ZhipuAI/chatglm-6b.git
```

百川智能（Baichuan）

```
git clone https://www.modelscope.cn/baichuan-inc/Baichuan2-7B-Base.git
git clone https://www.modelscope.cn/baichuan-inc/Baichuan2-13B-Base.git
git clone https://www.modelscope.cn/baichuan-inc/Baichuan-13B-Chat.git
```

- **深度求索（DeepSeek）**
- **智源研究院（BLOOMZ-zh 微调版）**

参考资料：

https://github.com/intel/intel-extension-for-transformers/tree/main

https://github.com/intel/intel-extension-for-transformers/blob/main/docs/installation.md